

Laboratório 2: Processamento de Bases de Dados em Lote

Arthur de Souza Medeiros

Questão 1: Estatísticas suficientes

As estatísticas suficientes são:

- `n_atraso`: número de voos com atraso maior que 10 minutos;
- `n_total`: número total de voos do grupo (dia, mês, cia. aérea).

Com esses dois valores dá pra calcular $\text{Perc} = n_{\text{atraso}} / n_{\text{total}}$, e como soma de somas é igual à soma total, eles podem ser acumulados chunk por chunk sem precisar guardar os voos individuais.

```
library(readr)
library(dplyr)
library(ggcal)
library(ggplot2)
```

Questão 2: Função `getStats`

```
getStats <- function(input, pos) {

  resultado <- input %>%
    filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%
    filter(!is.na(ARRIVAL_DELAY)) %>%
    group_by(DAY, MONTH, AIRLINE) %>%
    summarise(
      n_atraso = sum(ARRIVAL_DELAY > 10),
      n_total = n(),
      .groups = "drop"
    )

  return(resultado)
}
```

Questão 3: Leitura em lotes com `read_csv_chunked`

```
resultados_parciais <- read_csv_chunked(
  file = "flights.csv.zip",
  callback = DataFrameCallback$new(getStats),
  chunk_size = 100000,
  col_types = cols_only(
    MONTH = col_integer(),
```

```

    DAY          = col_integer(),
    AIRLINE      = col_character(),
    ARRIVAL_DELAY = col_integer()
  )
}

```

Questão 4: Função computeStats

```

computeStats <- function(dados) {

  final <- dados %>%
    group_by(AIRLINE, MONTH, DAY) %>%
    summarise(
      n_atraso = sum(n_atraso),
      n_total  = sum(n_total),
      .groups = "drop"
    ) %>%
    mutate(
      Data = as.Date(paste(2015, MONTH, DAY, sep = "-")),
      Perc = n_atraso / n_total,
      Cia  = AIRLINE
    ) %>%
    select(Cia, Data, Perc)

  return(final)
}

resultado_final <- computeStats(resultados_parciais)
resultado_final

```

```

# A tibble: 4 x 3
  Cia   Data      Perc
<chr> <date>   <dbl>
1 AA   2015-01-01 0.242
2 DL   2015-01-01 0.0886
3 UA   2015-01-01 0.215
4 US   2015-01-01 0.167

```

Questão 5: Mapas de calor em formato de calendário

```

pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")

baseCalendario <- function(stats, cia) {
  sub <- stats %>% filter(Cia == cia)
  calendario <- ggcal(sub$Data, sub$Perc)
  return(calendario)
}


cAA <- baseCalendario(resultado_final, "AA")
cDL <- baseCalendario(resultado_final, "DL")
cUA <- baseCalendario(resultado_final, "UA")
cUS <- baseCalendario(resultado_final, "US")

```

```
cAA + pal + ggtitle("American Airlines")
```

American Airlines


January



```
cDL + pal + ggtitle("Delta Airlines")
```

Delta Airlines


January



```
cUA + pal + ggtitle("United Airlines")
```

United Airlines


January



```
cUS + pal + ggtitle("US Airways")
```

US Airways

January



Horário de compilação

```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-25 00:00:00 -03"
```