Lab 8: Dados Relacionais com Polars

Arthur Medeiros

Leitura dos dados

Os arquivos são `.tsv.gz` (colunas separadas por tab) e `\N` indica valor faltante.

```
library(polars)

basics <- pl$read_csv("title.basics0.tsv.gz",
                      separator = "\t", null_values = "\\N", quote_char = NULL)
```

```
Warning: ! The default value of `infer_schema_files` will change in polars 2.0.
i The default will change from using all files to 10 files in Polars 2.0. Use
  `infer_schema_files = 10` to opt into the new default or `infer_schema_files
  = NULL` to keep using all files.
This warning is displayed once every 8 hours.
```

```
ratings <- pl$read_csv("title.ratings.tsv.gz",
                      separator = "\t", null_values = "\\N", quote_char = NULL)
principals <- pl$read_csv("title.principals0.tsv.gz",
                          separator = "\t", null_values = "\\N", quote_char
= NULL)
```

Preparação: juntar filmes com suas notas

Primeiro, fico só com os títulos que são filmes.

```
so_filmes <- basics$filter(pl$col("titleType") == "movie")
```

Depois, junto com a tabela de notas pela coluna em comum `tconst`.

```
filmes <- so_filmes$join(ratings, on = "tconst", how = "inner")
```

Questão 1

Ordenei por nota (maior primeiro) e, em caso de empate, por número de votos (maior primeiro).

```
ordenado <- filmes$sort("averageRating", "numVotes",
                        descending = c(TRUE, TRUE))

ordenado   <-   ordenado$select("tconst",   "primaryTitle",   "averageRating",
"numVotes")

q1 <- ordenado$head(5)
q1
```

```
shape: (5, 4)
┌─────────────┬──────────────────────────┬─────────────────┬────────────┐
│ tconst      ┆ primaryTitle             ┆ averageRating ┆ numVotes │
│ ---         ┆ ---                      ┆ ---             ┆ ---        │
│ str         ┆ str                      ┆ f64             ┆ i64        │
╞═════════════╪══════════════════════════╪═════════════════╪════════════╡
│ tt33075815 ┆ Kaveri                   ┆ 10.0          ┆ 1023     │
│ tt27815015 ┆ Kurukku                  ┆ 10.0          ┆ 451      │
│ tt28450376 ┆ Jedal Dar Omghe 30 Metri ┆ 10.0          ┆ 142      │
│ tt27859713 ┆ Sargashte                ┆ 10.0          ┆ 134      │
│ tt33507675 ┆ Gorgeous Rascal          ┆ 10.0          ┆ 115      │
└─────────────┴──────────────────────────┴─────────────────┴────────────┘
```

Resposta: todos os cinco filmes têm nota 10.0, então o desempate por votos define a ordem: Kaveri (1023 votos), Kurukku (451), Jedal Dar Omghe 30 Metri (142), Sargashte (134) e Gorgeous Rascal (115).

Questão 2

```
notas_altas <- filmes$filter(pl$col("averageRating") > 8)

notas_altas <- notas_altas$drop_nulls("genres")

notas_altas <- notas_altas$with_columns(pl$col("genres")$str$split(","))

generos <- notas_altas$explode("genres")
```

```
Warning: ! The default value of `empty_as_null` in `explode()` will change from
TRUE to
  FALSE in Polars 2.0.
ℹ Explicitly set `empty_as_null` to suppress this warning.
This warning is displayed once every 8 hours.
```

```
contagem <- generos$group_by("genres")$agg(pl$len()$alias("n"))

q2 <- contagem$sort("n", descending = TRUE)$head(5)
q2
```

```
shape: (5, 2)
┌─────────────┬───────┐
│ genres      ┆ n     │
│ ---         ┆ ---   │
│ str         ┆ u32   │
╞═════════════╪═══════╡
│ Documentary ┆ 10564 │
│ Drama       ┆ 8114  │
│ Comedy      ┆ 3186  │
│ Biography   ┆ 1395  │
│ Romance     ┆ 1363  │
└─────────────┴───────┘
```

Resposta: o gênero mais frequente é Documentary, com 10.564 filmes, seguido de Drama (8.114) e Comedy (3.186).

Questão 3

```
bons <- filmes$filter(pl$col("averageRating") > 7.5)$select("tconst")

atores <- principals$filter(
  (pl$col("category") == "actor") | (pl$col("category") == "actress")
)

atores_bons <- atores$join(bons, on = "tconst", how = "inner")

contagem3 <- atores_bons$group_by("nconst")$agg(
  pl$col("tconst")$n_unique()$alias("n_filmes")
)

q3 <- contagem3$sort("n_filmes", "nconst",
                     descending = c(TRUE, FALSE))$head(3)
q3
```

```
shape: (3, 2)
┌───────────┬───────────┐
│ nconst    ┆ n_filmes  │
```

```
| ---         | ---      |
| str         | u32      |
╞═════════════╪══════════╡
| nm0004660   | 199      |
| nm0595934   | 155      |
| nm3183374   | 124      |
└─────────────┴──────────┘
```

Resposta: os três atores/atrizes que mais participaram de filmes com nota maior que 7.5 são `nm0004660` (199 filmes), `nm0595934` (155 filmes) e `nm3183374` (124 filmes). Como não há tabela de nomes neste lab, as pessoas são identificadas pelo código `nconst`.